

Tema 2 – Sistem simplificat de indexare a fișierelor

Structuri de Date

Data postării: 27.04.2026

Deadline: 17.05.2026 ora 23:59

1 Descriere

În cadrul unui sistem simplificat de organizare a datelor, dorim să implementăm un mecanism de indexare a fișierelor pe baza cuvintelor-cheie asociate acestora.

Fiecare fișier este caracterizat prin:


- un identificator unic (numele fișierului);
- un scor de relevanță;
- o listă de cuvinte-cheie.

Scorul de relevanță este o valoare numerică ce indică cât de bine se potrivește un fișier cu o căutare, pe baza cuvintelor-cheie asociate. Un scor mai mare înseamnă o potrivire mai bună.

Sistemul trebuie să permită inserarea, ștergerea, actualizarea și căutarea fișierelor după cuvinte-cheie.

Pentru a exemplifica modalitatea în care vom stoca o astfel de colecție de fișiere, pornim de la următorul exemplu:

ID	Scor	Cuvinte-cheie
File1	95	algebra, analiza
File2	88	patrat, patrulater
File3	91	triunghi, trigonometrie
File4	84	tetraedru, paralelipiped
File5	99	algebra, trigonometrie, triunghi
File6	77	analiza, patrat, paralel



În această listă, fișierele vor fi reținute în ordinea în care acestea apar în sistem.

1.1 Arborele de regăsire

Pentru memorarea cuvintelor-cheie se va folosi un **arbore multicăi de regăsire**. Fiecare nod al arborelui corespunde unui caracter, iar un drum de la rădăcină până într-un nod terminal reprezintă un cuvânt-cheie complet. În nodurile terminale ale arborelui se vor păstra referințe către fișierele care conțin cuvântul respectiv.

Un exemplu de arbore pentru stocarea cuvintelor:

- algebra
- analiza
- patrat
- patrulater
- triunghi
- trigonometrie
- tetraedru
- paralelipiped
- paralel

este prezentat în figura următoare.




Figura 1: Exemplu de arbore de regăsire

Fișierele propriu-zise nu vor fi memorate în arbore, ci într-o **listă separată**, fiecare fișier având asociate informații despre identificator și scor. În acest arbore vom stoca pentru fiecare nod marcat o listă cu referințele spre fișierele care conțin drept cuvânt-cheie cuvântul corespunzător acelui nod terminal.

Pe lângă operațiile de bază (ADD, DEL, ADDKW, DELKW și FIND), sistemul trebuie să răspundă și la interogări de tip TOPK, prin care se cer cele mai relevante k fișiere asociate unui anumit cuvânt-cheie. Pentru această operație, referințele obținute din arbore trebuie organizate într-un **heap**, din care se vor extrage cele mai relevante fișiere.

În plus, pentru a permite modificarea incrementală a metadatelor, sistemul trebuie să suporte și:

- adăugarea unui cuvânt-cheie nou unui fișier existent;
- ștergerea unui cuvânt-cheie dintr-un fișier existent;
- afișarea conținutului arborelui într-un format simplu.

Observație importantă

Soluțiile care nu folosesc structurile de date impuse nu vor fi punctate.

2 Cerințe

În cadrul acestei teme, va trebui să implementați un sistem care gestionează următoarele tipuri de operații:

2.1 Operația ADD

Adaugă un nou fișier în sistem. Dacă identificatorul există deja, operația eșuează.

La adăugare:

1. se creează fișierul și se inserează în lista de fișiere;
2. pentru fiecare cuvânt-cheie al fișierului, se inserează cuvântul în arborele multicăi de regăsire;
3. în nodul terminal corespunzător cuvântului se adaugă o referință către fișier.

2.2 Operația DEL

Șterge fișierul cu identificatorul dat. Dacă fișierul nu există, operația eșuează.

La ștergere:

1. se identifică fișierul în lista de fișiere;
2. se elimină referințele lui din toate nodurile terminale corespunzătoare cuvintelor sale;
3. se elimină fișierul din lista de fișiere.

Dacă în urma ștergerii unui fișier apar în arbore noduri terminale care nu mai au asociată nicio referință la un fișier, trebuie să fie aplicată operația de ștergere pentru a elimina cuvântul respectiv din arborele de regăsire.

2.3 Operația ADDKW

Adaugă un cuvânt-cheie unui fișier existent.

Dacă fișierul nu există, operația eșuează. Dacă fișierul există deja și are deja asociat acel cuvânt-cheie, operația nu modifică sistemul, dar este considerată reușită.

La adăugare:

1. se identifică fișierul în lista de fișiere;
2. se verifică dacă acel cuvânt-cheie este deja asociat fișierului;
3. dacă nu este deja prezent, se inserează cuvântul în arborele multicăi de regăsire;
4. în nodul terminal corespunzător se adaugă referința către fișier.

2.4 Operația DELKW

Șterge un cuvânt-cheie dintr-un fișier existent.

Dacă fișierul nu există, operația eșuează. Dacă fișierul există, dar nu are asociat acel cuvânt-cheie, operația nu modifică sistemul, dar este considerată reușită.

La ștergere:

1. se identifică fișierul în lista de fișiere;
2. se verifică dacă acel cuvânt-cheie există în lista sa de cuvinte;
3. dacă există, se elimină referința către fișier din nodul terminal al cuvântului;
4. dacă nodul terminal nu mai conține nicio referință, cuvântul trebuie eliminat din arbore;
5. cuvântul-cheie se elimină și din lista de cuvinte a fișierului.

2.5 Operația FIND

Primește un cuvânt-cheie și trebuie să afișeze toate fișierele care conțin acel cuvânt.

Căutarea se face în arborele multicăi de regăsire, urmărind pe rând caracterele cuvântului. Dacă există un nod terminal pentru acel cuvânt, se vor afișa identificatorii fișierelor referite de acel nod, în **ordinea lexicografică a identificatorilor**.

Dacă după ștergerea cuvintelor rămâne vreun fișier fără niciun cuvânt-cheie asociat, acest fișier este șters din lista de fișiere.

2.6 Operația TOPK

Primește un cuvânt-cheie și o valoare k . Pe baza acestora, trebuie să determinați cele mai relevante k fișiere asociate cuvântului respectiv.

Pentru această operație:

1. se identifică nodul terminal corespunzător cuvântului;
2. se colectează toate referințele către fișierele asociate acelui cuvânt;
3. se construiește un **max-heap** pe baza acestor referințe (folosind pe post de prioritate scorul de relevanță pentru fiecare fișier);

4. se extrag primele k fișiere din heap.

Din perspectiva priorității, dacă vom avea mai multe fișiere cu același scor de relevanță, le vom sorta lexicografic după identificator.

Dacă pentru comanda TOPK nu există niciun rezultat, trebuie afișat **EMPTY**. În schimb, dacă vor exista rezultate, dar numărul acestora este mai mic decât valoarea lui k , atunci le vom afișa pe toate (la fel în ordinea specificată).

2.7 Operația PRINT

Pentru a permite testarea automată a structurii de indexare, sistemul trebuie să ofere și o comandă de afișare a arborelui într-un format simplu.

Comanda PRINT va afișa **toate cuvintele-cheie existente în arbore**, în **ordine lexicografică**. Pentru fiecare cuvânt-cheie se vor afișa:

1. cuvântul-cheie;
2. numărul de fișiere asociate;
3. identificatorii acestor fișiere în ordine lexicografică.

3 Formatul datelor de intrare

Pe prima linie se citește numărul de operații Q .

Urmează Q linii, fiecare reprezentând una dintre comenzile:

```
ADD id scor t cuvant1 cuvant2 ... cuvantt
DEL id
ADDKW id cuvant
DELKW id cuvant
FIND cuvant
TOPK cuvant k
PRINT
```

unde:

- id reprezintă identificatorul unic al fișierului;
- $scor$ reprezintă scorul de relevanță al fișierului;
- t reprezintă numărul de cuvinte-cheie asociate fișierului;
- $cuvant$ este un șir de caractere fără spații;
- k reprezintă numărul maxim de fișiere ce trebuie afișate.

4 Bonus (20 puncte)

Pentru un bonus de **20 de puncte**, se cere implementarea operației **PREFIX**, care extinde mecanismul de căutare asupra arborelui multicăi de regăsire.

4.1 Operația PREFIX

Primește un prefix și trebuie să determine toate fișierele care conțin **cel puțin un cuvânt-cheie ce începe cu prefixul dat**.

Observație Spre deosebire de FIND, unde se caută un cuvânt-cheie complet, la această operație se vor lua în considerare **toate cuvintele-cheie din arbore care au prefixul dat**.

Mod de lucru Pentru această operație:

1. se identifică în arbore nodul corespunzător ultimului caracter din prefix;
2. dacă prefixul nu există în arbore, operația nu are niciun rezultat;
3. dacă prefixul există, se parcurge întregul subarbore având rădăcina în acel nod;
4. pentru fiecare nod terminal întâlnit, se colectează referințele către fișierele asociate cuvântului complet;
5. dacă un fișier apare prin mai multe cuvinte-cheie compatibile cu prefixul, acesta se afișează **o singură dată**;
6. rezultatele finale se afișează în **ordinea lexicografică a identificatorilor**.

4.2 Formatul comenzii

PREFIX prefix

unde prefix este un șir de caractere fără spații.

4.3 Formatul datelor de ieșire

Pentru comanda PREFIX se va afișa:

- numărul de fișiere găsite, urmat de identificatorii lor în ordine lexicografică;
- EMPTY, dacă nu există niciun fișier asociat vreunui cuvânt-cheie care începe cu prefixul dat.

4.4 Exemplu

Input:

```
9
ADD File1 95 2 algebra analiza
ADD File2 88 2 patrat patrulater
ADD File3 91 2 triunghi trigonometrie
ADD File4 84 2 tetraedru paralelipiped
ADD File5 99 3 algebra trigonometrie triunghi
ADD File6 77 3 analiza patrat paralelipiped
PREFIX a
PREFIX tri
PREFIX te
```

Output:

```
OK
OK
OK
OK
OK
OK
3 File1 File5 File6
2 File3 File5
1 File4
```

4.5 Explicație

- Pentru PREFIX `a`, sunt luate în considerare cuvintele-cheie `algebra` și `analiza`. Fișierele asociate sunt:
 - `File1` (conține ambele cuvinte);
 - `File5` (conține `algebra`);
 - `File6` (conține `analiza`).

Rezultatul final este: `3 File1 File5 File6`.

- Pentru PREFIX `tri`, sunt luate în considerare cuvintele-cheie `triunghi` și `trigonometrie`. Fișierele asociate sunt `File3` și `File5`.
- Pentru PREFIX `te`, singurul cuvânt-cheie compatibil este `tetraedru`, asociat fișierului `File4`.

Condiție pentru acordarea bonusului

Operația PREFIX trebuie implementată prin parcurgerea arborelui multicăi de regăsire. Soluțiile care rezolvă această cerință fără utilizarea arborelui nu vor primi punctajul aferent bonusului.

5 Formatul datelor de ieșire

Pentru fiecare comandă se va afișa:

- OK pentru o operație reușită de tip `ADD`, `DEL`, `ADDKW` sau `DELKW`;
- EXISTS dacă la `ADD` identificatorul există deja;
- NOT FOUND dacă la `DEL`, `ADDKW` sau `DELKW` fișierul nu există;
- pentru `FIND`, numărul de fișiere găsite, urmat de identificatorii lor în ordine lexicografică;
- pentru `TOPK`, numărul de fișiere afișate, urmat de identificatorii lor în ordinea relevanței (descrescător);
- pentru `PRINT`, mai multe linii, câte una pentru fiecare cuvânt-cheie existent, în formatul:
`cuvant nr`
unde `nr` reprezintă numărul de fișiere asociate;

- pentru PREFIX, numărul de fișiere găsite, urmat de identificatorii lor în ordine lexicografică;
- EMPTY, dacă pentru FIND, TOPK, PRINT sau PREFIX nu există niciun rezultat.

6 Precizări importante

- În lista de cuvinte-cheie a unui fișier nu trebuie să existe duplicate.
- Dacă la ADD apar cuvinte duplicate în aceeași comandă, ele vor fi considerate o singură dată.
- La ADDKW, dacă perechea (id, cuvânt) există deja, se va afișa OK, fără alte modificări.
- La DELKW, dacă perechea (id, cuvânt) nu există, se va afișa OK, fără alte modificări.
- Pentru PRINT, ordinea lexicografică este făcută după șirurile reprezentând cuvintele-cheie.

Important

La operațiile DEL și DELKW, dacă în urma eliminării unei referințe un nod terminal nu mai are asociat niciun fișier, acel cuvânt-cheie se elimină din arborele de regăsire.

Eliminarea unui cuvânt din arbore înseamnă nu doar demarcarea nodului terminal, ci și ștergerea efectivă a nodurilor care devin inutile. Mai precis, după eliminarea referinței, se vor șterge recursiv toate nodurile care:

- nu mai sunt noduri terminale;
- nu mai au fii.

Procesul se oprește în primul nod care fie este terminal pentru un alt cuvânt-cheie, fie mai are cel puțin un fiu. În acest mod, arborele rămâne consistent și nu păstrează noduri inutile.

7 Restricții

- Identificatorul fișierului este un șir de caractere fără spații, iar scorul este un număr întreg.
- Un cuvânt-cheie are lungime de cel mult 100 de caractere și conține numai litere mici din alfabetul englez.
- Pentru memorarea cuvintelor-cheie se va folosi **obligatoriu** un arbore multicăi de regăsire.
- Pentru operația TOPK se va folosi **obligatoriu** un heap.
- Fișierele vor fi memorate într-o structură separată de arbore.
- Operațiile ADDKW și DELKW trebuie să actualizeze consistent atât lista de fișiere, cât și arborele.
- Operația PRINT trebuie implementată prin parcurgerea arborelui, nu printr-o structură auxiliară independentă care dublează indexul.

8 Exemplu

Input:

```
12
ADD File1 95 2 algebra analiza
ADD File2 88 2 patrat patrulater
ADD File3 91 2 triunghi trigonometrie
ADD File4 84 2 tetraedru paralelipiped
ADD File5 99 3 algebra trigonometrie triunghi
ADD File6 77 3 analiza patrat paralelipiped
FIND algebra
TOPK triunghi 3
ADDKW File4 triunghi
TOPK triunghi 4
DELKW File3 triunghi
PRINT
```

Output:

```
OK
OK
OK
OK
OK
OK
2 File1 File5
2 File5 File3
OK
3 File5 File3 File4
OK
algebra 2 File1 File5
analiza 2 File1 File6
paralelipiped 2 File4 File6
patrat 2 File2 File6
patrulater 1 File2
tetraedru 1 File4
trigonometrie 2 File3 File5
triunghi 2 File4 File5
```

Explicație:

După primele șase operații, sistemul conține:

- fișierul File1, cu scor 95 și cuvintele-cheie: algebra, analiza;
- fișierul File2, cu scor 88 și cuvintele-cheie: patrat, patrulater;
- fișierul File3, cu scor 91 și cuvintele-cheie: triunghi, trigonometrie;
- fișierul File4, cu scor 84 și cuvintele-cheie: tetraedru, paralelipiped;
- fișierul File5, cu scor 99 și cuvintele-cheie: algebra, trigonometrie, triunghi;
- fișierul File6, cu scor 77 și cuvintele-cheie: analiza, patrat, paralelipiped.

Pentru comanda `FIND algebra`, sunt găsite fișierele `File1` și `File5`, care se afișează în ordine lexicografică a identificatorilor.

Pentru comanda `TOPK triunghi 3`, fișierele asociate cuvântului `triunghi` sunt `File3` și `File5`. Acestea se ordonează descrescător după scor:

- `File5` cu scor 99;
- `File3` cu scor 91.

După comanda `ADDKW File4 triunghi`, fișierul `File4` devine asociat și cu acest cuvânt-cheie. Astfel, pentru `TOPK triunghi 4`, ordinea este:

- `File5` cu scor 99;
- `File3` cu scor 91;
- `File4` cu scor 84.

Prin comanda `DELKW File3 triunghi`, fișierul `File3` nu mai este asociat cu cuvântul `triunghi`, dar rămâne în sistem și continuă să fie asociat cu `trigonometrie`.

Comanda `PRINT` afișează toate cuvintele-cheie existente în arbore, în ordine lexicografică, împreună cu numărul fișierelor asociate fiecăruia.

9 Instrucțiuni de implementare

O rezolvare constă într-o arhivă de tip `.zip` care conține toate fișierele sursă, alături de un `Makefile` și un fișier `README`.

- `Makefile`-ul trebuie să conțină obligatoriu regulile `build` și `clean`.
- Regula `build` trebuie să aibă ca efect compilarea surselor și crearea binarului `search_index`.
- Programul va citi datele de intrare din fișierul `indexare.in` și va afișa rezultatele în fișierul `indexare.out`.

Observație

Pentru implementarea arborelui multicăi de regăsire se va utiliza reprezentarea prezentată la curs sau laborator pentru un arbore multicăi. Dacă au fost prezentate mai multe variante de reprezentare, alegeți voi una dintre acestea.

10 Recomandări de proiectare

Se recomandă o separare clară între:

- structura ce memorează fișierele;
- arborele multicăi de regăsire pentru cuvinte-cheie;
- heap-ul folosit la interogările `TOPK`;
- funcțiile de parsare și execuție a comenzilor.

11 Punctaj

Componentă	Punctaj
Implementarea corectă a operațiilor ADD, DEL	25 puncte
Implementarea corectă a operațiilor ADDKW și DELKW	15 puncte
Implementarea corectă a operației FIND folosind arborele	10 puncte
Implementarea corectă a operației TOPK folosind heap	30 puncte
Implementarea corectă a operației PRINT	10 puncte
README	5 puncte
Makefile, compilare fără erori/warning-uri	5 puncte
Bonus	20 puncte

Atenție!

- Orice rezolvare care nu conține structurile de date specificate **nu** va fi punctată.
- Pentru FIND este obligatorie utilizarea arborelui multicăi de regăsire.
- Pentru TOPK este obligatorie utilizarea unui heap.
- Operațiile DEL, ADDKW și DELKW trebuie să modifice atât arborele, cât și structura fișierelor.
- PRINT trebuie să reflecte conținutul arborelui după toate actualizările efectuate.
- README-ul trebuie să descrie clar reprezentarea structurilor de date, cum au fost implementate operațiile ce presupun prelucrarea acestor structuri.
- Temele vor fi punctate doar pentru testele care sunt trecute pe vmchecker.
- Nu lăsați warning-urile nerezolvate, deoarece veți fi depunțați.
- **Tema este individuală! Toate soluțiile trimise vor fi verificate, folosind o unealtă pentru detectarea plagiatului.**